

时间序列分析

课程小论文

题目 基于时间序列的江苏省地区生产总值预测方法探究

班 级 _____

专 业 信息与计算科学

学 号 _____

姓 名 _____

日 期 2023 年 11 月 5 日

基于时间序列的江苏省地区生产总值预测方法探究

摘 要

地区生产总值的合理预测对政府制定相关政策宏观调控城市发展与提升人民生活水平都有深远意义。本文选取长三角重要组成地区之一江苏省，探究自 1992 年南方谈话以来江苏省地区生产总值状况并进行未来 5 年的预测。

在模型拟合方面，本文拟合了如下四类模型，并逐一分析比较了模型适用性与局限性：

- 1) 对 GDP 序列的一元时间序列 ARIMA 模型建模，模型最终口径为：

$$y_t = 1.9697y_{t-1} - 0.9697y_{t-2} + \varepsilon_t, \varepsilon_t \sim N(0, 0.002026)$$

在拟合此模型时，针对模型是否包含漂移项进行 arima 函数与 Arima 函数对比，最终得出结论，本文研究对象更适用于不考虑漂移项的 arima 函数。

- 2) 用 LASSO 回归方法进行特征选择确定输入变量、Granger 因果检验后的多元协整动态回归模型，模型最终口径为：

$$Ln_GDP = 1.0720[Ln_S_I, Ln_T_I] + \frac{\varepsilon_t}{1 - 1.5016B + 0.5742B^2} \sim N(0, 0.000316)$$

- 3) 多元时间序列误差修正模型（ECM）建模，模型最终口径为：

$$\begin{aligned} \nabla LnGDP = & 0.093644\nabla Ln_F_I + 0.52966\nabla Ln_S_I \\ & + 0.375802\nabla Ln_T_I - 0.27516ECM_{t-1} + \varepsilon_t \end{aligned}$$

- 4) 基于多元时间序列的随机森林模型建模，其为非参数方法，无具体口径。

在模型预测方面，分别用一元 ARIMA 模型和多元协整回归模型预测未来 5 期，即 2023-2027 年度江苏省的地区生产总值，并进行比较，得出一元时序拟合与多元时序拟合在短期内拟合效果相当，在长期预测会在数值上出现较大偏差，但两者在总体趋势上都拟合良好的结论。

最后补充本文案例在干预分析问题方面存在的问题及可能原因，对地区生产总值预测方法做出总结与展望。

关键词：LASSO 回归特征选择；ARIMA 模型；协整动态回归；ECM 模型；随机森林模型

一、引言

生产总值（Gross Domestic Product,简称 GDP）是一个国家（或地区）所有常住单位在一定时期内生产活动的最终成果，是监测经济高质量发展的重要手段。其在国家层面称为国内生产总值（GDP），在地区层面称为地区生产总值（地区 GDP）。

江苏省作为长江三角洲地区重要组成部分之一，受 1992 年南方谈话后深化改革、加快发展方针的影响，经济水平持续高速增长。本文选取江苏省自 1993 年至今 30 年的地区生产总值数据，以探究在践行和实施社会主义市场经济体制这一创新性举措下江苏省的经济变化发展规律、分析江苏省经济产业结构，为进一步研究宏观经济决策提供坚实依据。

我国地区生产总值的核算制度也经历了关键性的改革。自 1985 年我国建立生产总值核算制度后，我国一直采取分级核算制度，即国家统计局核算国内生产总值，各级统计部门核算本地区生产总值，各级生产总值作为独立的总体单独核算，上一级生产总值不是由下一级地区生产总值汇总得到。后我国国家统计局对地区生产总值实施统一核算制度，即生产总值由下及上层层汇总，该核算制度于 2019 年正式开始应用。

二、数据基本统计分析

2.1 数据来源及概述

本文数据来自中国国家统计局网（<http://data.stats.gov.cn/easyquery.htm?cn=A01>），选取 1993 年至 2023 年国民经济核算指标下江苏省地区生产总值作为响应变量，同时将江苏省第一产业增加值、第二产业增加值、第三产业增加值、农林牧渔业增加值、工业增加值、建筑业增加值、批发和零售业增加值、交通和运输仓储和邮政业增加值、住宿和餐饮业增加值、金融业增加值、房地产业增加值、其它行业增加值等共计十二项指标作为可能的输入序列，对这些输入序列进行相关性分析和 LASSO 回归特征选择确定占主要作用的最终输入序列，便于后续对多元时间序列模型的探究。

2.2 响应序列描述性统计

2.2.1 符号说明

表 1

符号	说明	单位
GDP	1993-2022 年江苏省地区生产总值序列	亿元

Ln_GDP	1993-2022 年江苏省地区生产总值对数序列	亿元
Ln_F_I	1993-2022 年江苏省第一产业增加值对数序列	亿元
Ln_F_I	1993-2022 年江苏省第二产业增加值对数序列	亿元
Ln_F_I	1993-2022 年江苏省第三产业增加值对数序列	亿元
DIF_GDP	1993-2022 年江苏省地区生产总值对数的一阶差分序列	亿元
DIF_F_I	1993-2022 年江苏省第一产业增加值对数的一阶差分序列	亿元
DIF_S_I	1993-2022 年江苏省第二产业增加值对数的一阶差分序列	亿元
DIF_T_I	1993-2022 年江苏省第三产业增加值对数的一阶差分序列	亿元

2. 2. 2 响应序列描述性统计

表 2

平均	42132.2
标准误差	6968.865
中位数	28466.95
标准差	38170.05
方差	1.46E+09
峰度	-0.75382
偏度	0.757438
区域	119877.4
最小值	2998.2
最大值	122875.6
极差	119,877.4
求和	1263966
观测数	30

选取江苏省 1993-2023 年 30 年间的地区生产总值（亿元）为响应序列，响应序列数据描述性统计如上表。根据数据，计算得到 30 年间江苏省地区生产总值极差为 119,877.4 亿元，方差为 1.46×10^9 亿元，极差与方差都很大，意味着地区生产总值变化显著，有大幅度的提升。

2.2.3 响应序列及其变式时序图、ACF 图、PACF 图

绘制响应序列及其对数序列的时序图，可以看出响应序列有明显上升趋势。




图 1

对响应序列的对数序列进行一阶差分，提取线性趋势，得到差分后时序图、ACF 图、PACF 图。




图 2

由时序图（图 2 上）可知，一阶差分后的地区生产总值对数序列基本在 0 值附近小范围波动，且不具有长期趋势或季节趋势；由 ACF、PACF 图可知，序列的自相关性和偏自相关性都很快衰减为 0，由图检验可以初步判断序列平稳。

三、一元时间序列建模

3.1 基本原理

3.1.1 ARIMA 模型

ARIMA 模型是一种能良好拟合无季节效应的非平稳序列的模型，其具有如下结构：

$$\begin{cases} \Phi(B)\nabla^d x_t = \Theta(B)\varepsilon_t \\ E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, & s \neq t \\ E(x_s \varepsilon_t) = 0, & \forall s < t \end{cases}$$

式中， $\nabla^d = (1 - B)^d$ ； $\Phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ ，为平稳可逆 ARMA(p,q)模型的自回归系数多项式； $\Theta(B) = 1 - \theta_1 B - \dots - \theta_q B^q$ ，e 为平稳可逆 ARMA(p,q)模型的移动平均系数多项式。可以简记为 $\nabla^d x_t = \frac{\Theta(B)}{\Phi(B)} \varepsilon_t$ ，其中 ε_t 为零均值白噪声序列。

ARIMA 模型的实质是差分运算与 ARMA 模型的组合。这一关系意义重大，这说明任何非平稳序列如果能够通过适当阶数的差分实现差分后平稳，就可以对差分后序列进行 ARMA 模型拟合，而 ARMA 模型的分析方法非常成熟，这意味着对差分平稳序列的分析也将是非常简单、非常可靠的。

3.2 数据检验

3.2.1 平稳性检验

在响应序列描述性统计内容中，对原始响应序列数据取对数并进行一阶差分得到时序图、ACF 图、PACF 图，能初步判断该序列平稳。为准确判断响应序列的平稳性，继续对序列进行 ADF 检验。检验结果如表 3，可知，响应序列总是平稳的。

表 3

类型	Dickey-Fuller	P-值
no drift no trend	-2.294	0.0236
with drift no trend	-1.185	0.0242

3.2.2 白噪声检验

接着，对响应序列进行纯随机性检验，检验结果如表 4，可以获知，无论是延迟 6 阶还是 12 阶，序列都为非白噪声序列。

表 4

延迟阶数	P-值
6	0.008904
12	0.02613

综上，经一阶差分后的地区生产总值对数序列是平稳非白噪声序列，可以尝试用 ARIMA 模型对其进行拟合。

3.3 拟合模型

3.3.1 模型定阶

截取响应序列中的前 25 组作为训练集，即对 1993 年至 2017 年江苏省地区生产总值的对数序列进行模型拟合。观察训练集序列的 ACF、PACF 图（图），偏自相关系数图显示 1 阶截尾特征，而自相关图显示拖尾特性，考虑用 AR(1)模型拟合一阶差分后序列，即对训练集序列进行 ARIMA(1,1,0)模型的拟合。




图 3

3.3.2 函数选择

在对有一阶差分运算的序列进行模型拟合时，是否加入漂移项会对序列预测有较大的影响。有差分运算的场合，漂移项是指差分后序列的均值

$$\mu = E[(1 - B)^d x_t],$$

代入本文中的 ARIMA(1,1,0)模型即为 $\mu = E[\nabla x_t] = c(1 - \phi_1)$,

stats 程序包中的 `arima` 拟合函数忽略了漂移项, 而 `forecas` 程序包中的 `Arima` 函数考虑了漂移项的序列信息。为更精准地获得预测模型, 本文对响应序列分别进行考虑漂移项与不考虑漂移项两类模型的拟合, 比较后选择其一。

令 `Arima` 函数拟合的模型为 `y_fit1`, `arima` 函数拟合的模型为 `y_fit2`。指定两类模型阶数都为 $(1,1,0)$, 得到模型参数如下:

表 5

Arima(1,1,0)			arima(1,1,0)	
系数		模型优度	系数	模型优度
arl	drift		arl	
0.8061	0.1562	AIC=-78.92	0.94790	AIC=-77.41
0.1483	0.0384	BIC=-75.38	0.0273	

3.4 模型检验

3.4.1 模型显著性检验

对 `Arima` 函数构建的模型进行模型显著性检验 (图 4), 考察残差序列的白噪声检验结果, 可以看出各阶延迟下白噪声检验统计量的 p 值均大于 0.05, 认为模型拟合的残差序列属于白噪声序列, 模型显著性检验通过。




图 4

对 arima 函数构建的模型进行模型显著性检验，由图 5 易知模型显著性检验也通过。




图 5

3.4.2 参数显著性检验

根据表 6 中 y_fit1 和 y_fit2 模型的系数均大于两倍标准差可近似判断模型参数均显著，但由于样本数量较少，仍需进一步对参数显著性进行探究。

精确判断参数显著性的方法是构造 t 统计量：

$$t = \frac{\hat{\phi}_j}{\sigma_j} \cdots t(n-m)$$

$$\text{式中, } \hat{\sigma}_j = \sqrt{\frac{a_{jj}Q(\hat{\beta})}{n-m}}.$$

调用 R 语言中 pt 函数得到 t 统计量的 p 值，无论选择哪个函数，模型所有参数 t 统计量的 p 值都远远小于 0.05，表明拟合响应训练集序列的模型参数都显著非零。

表 6


Arima(1,1,0)		arima(1,1,0)	
系数	P 值	系数	P 值
arl	7.97×10^{-6}	arl	1.12×10^{-22}
drift	2.38×10^{-4}		

3.5 模型预测

3.5.1 模型精确度比较

在拟合模型时，本文截取响应序列的前 25 组作为训练集，则后 5 组可以用作测试集比较所拟合模型的精确度。分别用 y_fit1 和 y_fit2 预测未来 5 期序列值，即 2018-2022 年度江苏省的地区生产总值。

绘制带漂移项与不带漂移项模型的拟合及预测图，可以看出，两个模型的预测趋势都是线性递增，不带漂移项的模型预测斜率稍平缓。将模型预测值，测试集的实际值及两者误差构成表格（表 7）并求出误差项的均值。






图 6

表 7

y_fit1预测值	真实值	误差	y_fit2 预测值	真实值	误差
11.47509	11.44258	-0.03251	11.46287	11.44258	-0.02029
11.59767	11.4994	-0.09827	11.56301	11.49940	-0.06360
11.72677	11.54062	-0.18615	11.66104	11.54062	-0.12042
11.86112	11.67328	-0.18784	11.75700	11.67328	-0.08373
11.99969	11.71893	-0.28077	11.85096	11.71893	-0.13203
误差均值:	-0.15711		误差均值:	-0.08401	
误差方差:	0.00902		误差方差:	0.00203	

带漂移项的模型误差均值为-0.1571072，不带漂移项的模型误差均值为 -0.08401343，带漂移项模型的误差方差和均值均比不带漂移项模型小，即经测试集验证得到使用 `arima` 函数的 `y_fit2` 模型预测效果更优。

综上，在下节序列预测部分选择使用 `arima(1,1,0)`模型对响应序列进行预测。

3.5.2 序列预测

由于对时间序列的预测是基于已知历史信息对未来某个时期的发展水平做出估计，需要估计的时间越长，未知信息量就越多，估计的精度越低，所以在进行序列预测时要尽可能使用已知信息，即将 1993 年至 2022 年所有 30 组序列值都用于模型拟

合。

由上节结论，对所有响应序列进行不带漂移项的 ARIMA(1,1,0)模型拟合。得到模型 ar1 项系数为 0.9697，则最终模型可表示为：

$$\nabla y_t = 0.9697 \nabla y_{t-1} + \varepsilon_t$$

展开差分运算得到等价表达式为

$$y_t = 1.9697 y_{t-1} - 0.9697 y_{t-2} + \varepsilon_t, \varepsilon_t \sim N(0, 0.002026)$$

进行未来 5 期的序列预测。模型显著性与参数显著性检验均通过，得到预测值并绘制预测曲线（表 8、图 7）。

表 8

时间	预测值	Lo.95	Hi.95	预测 GDP
2023	11.76319	11.67497	11.85142	128437
2024	11.80612	11.61122	12.00101	134070
2025	11.84774	11.52541	12.17007	139768
2026	11.88810	11.42163	12.35456	145524
2027	11.92723	11.30276	12.55170	151332




图 7

对预测值进行指数变化得到预测的 2023 至 2027 年度江苏省地区生产总值。根据预测，江苏省年度 GDP 在 2027 年将达到 151332 亿元。

四、（多元时间序列）二元或干预分析

4.1 LASSO 回归法特征选择

4.1.1 LASSO 回归法基本原理

Lasso 回归（Least Absolute Selection and Shrinkage Operator），即最小绝对值选择与收缩算子。Lasso 回归法是一种改良的最小二乘算法，是以缩小变量集为思想的压缩估计方法，它通过构造一个惩罚函数，将变量的系数进行压缩并使某些回归系数变为 0，进而达到变量选择的目的。

Lasso 回归的目标函数一般形式为：

$$f(w) = \sum_{i=1}^m (y_i - x_i^T w)^2 + \lambda \sum_{i=1}^n |w_i|$$

其中， λ 为非负正则化参数， $\lambda \sum_{i=1}^n |w_i|$ 为惩罚函数，随着 λ 增大，惩罚项变大，保留的变量就越少。

4.1.2 特征选择输入变量确定

根据国家统计网上的原始数据，可能的输入序列有 12 组，对这些序列进行相关性分析，得到相关阵，可视化如下




图 8

可以看出，备选的 12 组输入序列间具有极高的相关性，所以从中选择最具有代表性的数据作为最终输入序列可以有效帮助我们构建多元时间序列模型。

使用 R 语言中的 lars 程序包对原始数据进行 Lasso 回归，压缩后的变量系数如表 9，可以看出，第一产业增加值、第二产业增加值、第三产业增加值系数较高，其它 9 组系数均接近 0，故选取第一产业增加值、第二产业增加值、第三产业增加值作为主要特征，在多元时间序列建模中与地区生产总值构建多元模型。

表 9

备选序列	回归系数
第一产业增加值(亿元)	1.0031
第二产业增加值(亿元)	1.1371
第三产业增加值(亿元)	1.0055
农林牧渔业增加值(亿元)	0.0000
工业增加值(亿元)	-0.1370

建筑业增加值(亿元)	-0.1370
批发和零售业增加值(亿元)	-0.0040
交通运输、仓储和邮政业增加值(亿元)	-0.0098
住宿和餐饮业增加值(亿元)	-0.0109
金融业增加值(亿元)	-0.0068
房地产业增加值(亿元)	-0.0065
其他行业增加值(亿元)	-0.0048

4.2 Granger 因果检验

为进一步检验 4.1 节中拟确定的输入序列与响应序列间具有真正的因果关系，分别对 DIF_F_I 、 DIF_S_I 、 DIF_T_I 与 DIF_GDP 序列进行 Granger 因果检验。

4.2.1 基本原理

Granger 因果检验的基本思想是，如果自变量事件的发生对于因变量事件的预测精度能有显著提高，则认为自变量是因，因变量是果，两者间存在显著因果关系。其原假设为任意两个时间序列相互独立，即自变量序列不是因变量序列的 Granger 原因，故在假设检验时拒绝原假设才能判定自变量序列是因变量序列的原因。

4.2.2 因果检验

Granger 因果检验的前提是因果序列都平稳，由 3.2.1 节可知，序列 DIF_GDP 是平稳的，于是对 DIF_F_I 、 DIF_S_I 、 DIF_T_I 序列进行平稳性检验（表 10）。由检验结果可知，拟输入变量序列一阶差分后均平稳，符合 Granger 因果检验条件。

表 10

序列	类型	延迟阶数	P-值
DIF_F_I	no drift no trend	0	0.0100
DIF_S_I	no drift no trend	0	0.0210
DIF_T_I	no drift no trend	0	0.0441

因为 Granger 因果检验的阶数严重依赖于解释变量的阶数，所以对三个拟输入序列与响应序列进行互相关分析，绘制互相关系数图与因变量自相关图如图 9。

左上图显示， Ln_GDP 序列进行一阶差分后，自相关系数很快衰减为 0，在延迟

2 阶时就落入两倍表差内,是典型平稳序列特征,故对 Ln_GDP 序列引入 1 阶延迟(差分)。剩余三幅图显示, Ln_GDP 与 Ln_F_I 、 Ln_S_I 、 Ln_T_I 均在 0 阶延迟达到互相关系数最大。综合以上信息,本文引入各变量的 1 阶延迟进行 Granger 因果检验。

表 11 结果显示,任意拟自变量和因变量序列间 Granger 因果检验的 p 值都小于 0.05,拒绝两序列独立的原假设,两两序列间相互影响,互为因果,即两者间存在反馈关系。所以选择 Ln_F_I 、 Ln_S_I 、 Ln_T_I 作为多元序列的输入序列, Ln_GDP 作为多元序列的响应序列通过 Granger 因果检验。




图 9

表 11

序列	F 统计量	P-值
$Ln_GDP \rightarrow Ln_F_I$	26.205	2.455×10^{-5}
$Ln_F_I \rightarrow Ln_GDP$	8.6889	0.00668
$Ln_GDP \rightarrow Ln_S_I$	8.2693	0.007942
$Ln_S_I \rightarrow Ln_GDP$	5.0177	0.03386

$Ln_GDP \rightarrow Ln_T_I$	7.0042	0.01362
$Ln_T_I \rightarrow Ln_GDP$	22.824	6.047×10^{-5}

4.3 协整检验

为建立多元时间序列模型，在响应变量与因变量均不平稳的情况下，我们需要考察序列间是否存在协整关系。绘制取对数后的江苏省地区生产总值、第一产业增加值、第二产业增加值、第三产业增加值曲线，由图 10 可以看出 Ln_S_I 、 Ln_T_I 序列与 Ln_GDP 序列有明显长期均衡关系，而 Ln_F_I 序列与 Ln_GDP 序列也都在总体上呈线性递增趋势，由于图检验只能对协整关系进行大致判断，于是接着用 EG 检验进一步验证序列间的协整关系。




图 10

EG 检验的基本原理是建立响应序列与输入变量之间的回归模型，再对回归残差序列进行平稳性检验，若回归残差序列通过平稳性检验，则两个变量间存在协整关系。

分别对 Ln_F_I 、 Ln_S_I 、 Ln_T_I 与 Ln_GDP 构造回归模型并对残差序列进行平稳性检验，检验结果如下表 12，检验表明三个自变量与因变量序列回归残差序列都通过了平稳性检验，即响应序列和输入序列存在协整关系，可以对多元非平稳序列建立动态回归模型。

表 12

变量	类型	延迟阶数	P-值
Ln_F_I 与 Ln_GDP	no drift no trend	2	0.0108
Ln_F_I 与 Ln_GDP	no drift no trend	4	0.0100
Ln_F_I 与 Ln_GDP	with drift no trend	4	0.036

综上, 本文最终确认输入变量序列为 $\{Ln_F_I、Ln_S_I、Ln_T_I\}$, 响应变量序列为 $\{Ln_GDP\}$, 进行多元时序分析的模型拟合与预测。

4.4 协整动态回归模型建立

4.4.1 模型拟合

由 4.3 节可知, 由于序列 Ln_GDP 与序列 Ln_F_I 、 Ln_S_I 、 Ln_T_I 间存在协整关系, 所以对响应序列与输入序列拟合协整动态回归模型。在 R 语言进行实验时, 系统提示只能选择 2 个自变量构成矩阵作为输入序列, 故依据时序图选择协整关系较明显的第二产业增加值与第三产业增加值作为协整动态回归模型的输入序列,

得到模型参数如表 13, 表中显示输入序列前系数值大于两倍标准差, 即系数显著。利用最小二乘思想, 构造响应序列与输入序列的回归关系为

$$Ln_GDP = 1.0720[Ln_S_I, Ln_T_I] + \varepsilon_t$$

表 13

输入序列	$\{Ln_S_I、Ln_T_I\}$	响应序列	Ln_GDP
系数	1.0720	系数标准差	0.0013
Sigma^2	0.004545	AIC	-72.68

继续对动态回归模型的残差序列进行白噪声检验 (p 值为 2.931×10^{-14}), 发现残差序列不是纯随机序列, 还需要进一步提取残差序列中蕴含的相关信息。残差序列的 ACF、PACF 图如图 11, 可知自相关图拖尾, 偏自相关图 1 阶截尾。经过多次调试, 最终对残差序列进行 AR(2)模型拟合。得到最终模型参数 (表 14), 根据系统输出结果, 得到最终协整动态回归模型的口径为

$$Ln_GDP = 1.0720[Ln_S_I, Ln_T_I] + \frac{\varepsilon_t}{1 - 1.5016B + 0.5742B^2} \sim N(0, 0.000316)$$




图 11

表 14

变量	系数	系数标准差
ar1	1.5016	0.1508
ar2	-0.5742	0.1514
$\{Ln_S_I、Ln_T_I\}$	1.0720	0.0042
Sigma ² :0.000316		AIC:-145.45




图 12

对建立完成的协整动态回归模型进行残差白噪声检验，得到残差序列 p 值为 0.7985，即新构造模型的残差序列已为纯随机序列，没有更多相关信息需要提取。对协整动态回归模型进行参数显著性检验与模型显著性检验，表 14 显示，三个变量的系数均大于两倍标准差，参数均显著非零。拟合模型显著图（图 12）可知，各阶延迟下白噪声检验统计量 p 值均大于 0.05，拟合的协整动态回归模型显著成立。可以利用此协整模型进行对响应序列的预测。

4.4.2 模型意义

协整动态回归模型显示，江苏省地区生产总值既会受到前两年度地区生产总值的影响（2 阶自相关），也会受到地区第二产业增加值和第三产业增加值影响（自变量与因变量间的协整关系），从回归系数来看，每增加 1 单位的对数第二产业增加值和第三产业增加值，长期而言会增加 1.0720 单位的对数地区生产总值，这说明第二产业增加值与第三产业增加值的增长显著推动地区生产总值增长，并且还存在着其它因素导致地区生产总值增长。在制定经济政策推动城市地区生产总值上升时，要格外注重第二产业和第三产业的发展，这两大产业的蓬勃发展将是城市焕发昂扬风貌的重要源泉。

4.5 序列预测

通过 4.4 节协整动态回归模型的建立，我们知道江苏省地区生产总值会受到地区第二产业增加值和第三产业增加值的较大影响。为使对地区生产总值的预测更为精确，本文将首先进行对第二产业增加值和第三产业增加值的预测，再将预测值代入协整模型，以获得响应序列预测值。

4.5.1 输入序列预测

通过单变量拟合方法对第一产业增加值、第二产业增加值、第三产业增加值拟合模型并进行未来 5 期的预测。由 4.4.2 节表 10 可知，三类产业增加值一阶差分后的对数序列均为平稳序列，白噪声检验结果表 15 显示，三类产业增加值一阶差分后的对数序列均为纯随机序列，故可用 ARIMA 模型对输入序列进行拟合。

对第一产业对数增加值构造 ARIMA(1,1,1)模型，对第二产业对数增加值构造 ARIMA(1,1,0)模型，对第三产业对数增加值构造 ARIMA(1,1,0)模型，分别预测得到未来五期序列预测值如表 15。

表 15

序列	延迟阶数	P-值
DIF_F_I	6	0.02613
DIF_S_I	6	0.05645
DIF_T_I	6	0.008904

表 16

时间	Ln_F_I 预测值	Ln_S_I 预测值	Ln_T_I 预测值
2023	8.56430	10.98743	11.06764
2024	8.61272	11.04103	11.09892
2025	8.65517	11.09205	11.12922
2026	8.69237	11.14062	11.15856
2027	8.72498	11.18686	11.18697

4.5.2 响应序列预测

将 4.5.1 中所得第二产业增加值、第三产业增加值对数序列代入协整动态模型，即可得到未来 5 期地区生产总值对数序列的预测值，再对该对数预测序列进行指数变换，得到最终未来 5 期地区生产总值预测值与时序图。




图 13

表 17

时间	预测值	Lo.95	Hi.95	预测 GDP
2023	11.76902	11.73418	11.80386	129187.8
2024	11.82126	11.75841	11.88412	136116.2
2025	11.87402	11.78812	11.95993	143490.1
2026	11.92617	11.82259	12.02976	151171.8
2027	11.97698	11.86049	12.09346	159050.3

比较对响应序列构造的一元时序模型的预测值与多元协整回归模型的预测值，可知两个模型预测值在未来 2 期内预测差别都不大，在预测 3 期后预测值开始出现较大差异。但总的来说，到 2027 年，江苏省地区生产总值都将超过 15 万亿元，城市发展势态良好。

4.6 误差修正模型建立

协整模型反映输入序列与输出序列间的长期均衡关系，而误差修正模型（error correction model）则解释序列的短期波动关系，其常常作为协整模型的补充模型出现。

为研究江苏省地区生产总值与第一、第二、第三产业增加值间的短期波动特征，利用一阶差分后序列 $\{DIF_F_I, DIF_S_I, DIF_T_I\}$, $\{DIF_GDP\}$ 和前期误差序列 $\{ECM_{t-1}\}$ 构建 ECM 模型。输出结果如表 18 所示。

表 18

序列	系数估计值	标准误差	t 值	Pr(> t)
DIF_F_I	0.093644	0.010761	8.702404	6.89E-09
DIF_S_I	0.52966	0.013295	39.84001	1.94E-23
DIF_T_I	0.375802	0.016266	23.10406	6.62E-18
ECM	-0.27516	0.143131	1.922443	0.066497

根据系统输出结果，最终 ECM 模型为

$$\nabla \ln GDP = 0.093644 \nabla \ln F_I + 0.52966 \nabla \ln S_I + 0.375802 \nabla \ln T_I - 0.27516 ECM_{t-1} + \varepsilon_t$$

方程检验 p 值为 2.2×10^{-16} ，方程显著线性相关，参数检验结果（表）显示输入

变量当期波动对响应变量当期波动均有显著影响，但上期误差（ECM 项）系数不大于两倍标准差，即 ECM 项对当期波动影响不显著。从 ECM 模型系数还可获知，第二产业和第三产业增加值系数较大，对地区生产总值影响较大，与 4.4 节中协整动态回归模型选择第二产业和第三产业增加值为输入序列结论相符。

ECM 项系数为-0.27516，表明上期误差对地区生产总值的当期波动具有负反馈机制。在经济意义上的解释为，当上期的真实地区生产总值比预期地区生产总值小时，相关部门应当及时调整城市建设战略，制定相关计划使得当期地区生产总值得到增加。

4.7 随机森林模型建立

4.7.1 算法原理

随机森林（Random Forest）是一种强大的机器学习算法，最初用于解决分类和回归问题。随机森林算法采用了集成学习的方法，将多个基本模型即决策树组合成一个更强大的模型，并引入随机性来增加模型的多样性，从而提高预测性能。每个决策树通过自助采样和随机特征选择来训练，然后通过投票或平均的方式组合它们的预测结果。这一决策机制降低了过拟合的风险，并使随机森林适用于多元时间序列问题。

随机森林模型的实现步骤可大致分为以下三步：

数据拆分：该过程通过特征拆分，每一行负责创建决策树。

决策：每棵树都根据数据做出自己的决策。

决策聚合：在这一步中，树的平均值预测成为最终结果。

代入本文拟合生产总值的情境，即是决策树对输入序列做出拆分后，根据训练集的输入序列数据特征和响应变量值做出决策，从数据中学习出复杂的非线性关系。最后对构建好的模型输入测试集中数据，得到估计值，再将估计值与真实值比较，判断模型拟合好坏。

4.7.2 算法实现

首先对原数据划分训练集与测试集，原数据为 1993-2022 年共 30 年的地区生产总值，随机挑选其中 24 组为训练集，进行随机森林模型的训练。待模型训练完成后，代入剩余 6 组的输入序列，获取模型预测值，将测试集的预测值、真实值及两者的误差整理成表格（表 19）。

随机挑选的测试集年份为 {1995 年、1998 年、2001 年、2011 年、2018 年、2019 年、2021 年}，由表中结果可知，预测误差的绝对值最小值为 0.01812，最大值为 0.16272，

均值为 0.081。预测误差总体较小，模型拟合效果较好。

表 19

年份	预测值	真实值	误差
1995 年	8.67799	8.54778	0.13021
1998 年	8.86372	8.88184	-0.01812
2001 年	9.10109	9.15449	-0.05340
2011 年	10.88362	10.79629	0.08733
2018 年	11.37595	11.44258	-0.06663
2019 年	11.45028	11.49940	-0.04912
2021 年	11.51056	11.67328	-0.16272

五、 总结与展望

本文对地区生产总值序列共计拟合了四种模型，其中一元 ARIMA 模型、多元协整回归模型和 ECM 模型为参数模型，可以具体写出表达式，随机森林模型为非参数模型，通过内部构造决策树、取均值等方式获取预测值。

四种模型中，一元 ARIMA 模型是根据地区生产总值序列本身的特征进行拟合与预测，多元协整回归模型反映输入序列与响应序列的长期依赖关系，这两种模型都适合对序列做出未来的预测；而 ECM 模型反映输入序列与响应序列的短期波动关系，不适合进行序列预测，随机森林模型反映输入序列与响应序列的非参数关系，在模型拟合方面效果较好，但在预测时由于缺乏未来输入序列的真实值，即使使用输入序列的预测值，对响应序列的预测效果也不好，同样不适用于序列的预测。

随机森林模型在拟合时无需对响应序列和输入序列做差分、检验平稳性等操作，只需提供数据即可，且其预测精度较高，在已知输入序列预测时有很大的应用优势。

此外，引言中提到，我国核算地区生产总值的方式在 2019 年进行了变革，对这一政策影响进行干预分析，但得到结果此项干预几乎无影响，可能是统计局对改革前数据都已进行更新修正的缘故。

对江苏省地区生产总值的预测方法探究让我更为清晰地认识到对于时间序列的多种拟合模型与方法在不同场景下的适用性。地区生产总值作为衡量城市发展状况与人民生活水平的重要指标，对其的准确预测有着深远意义，更多的预测方法仍等待着我们去学习与探究。

附录

附录 1 代码
介绍：读取数据、计算相关性 <pre> library(readxl) library(aTSA) library(tseries) library(forecast) library(psych) library(tidyverse) library(stats) library(ggcorrplot) install.packages('aTSA') library('aTSA') #读取数据，计算相关性 d<-read_excel("D:/新建文件夹 (5)/大三/时间序列分析/期末作业/分省年度数据.xls",2) x=d[,3:14] # 自变量 y=d[,2] # 因变量 x1<-as.matrix(x) y1<-as.matrix(y) x1t<-as.matrix(d[,15]) cor_da<-data.frame(cor(x)) #write_excel_csv(cor_da, file ="D:/新建文件夹 (5)/大三/时间序列分析/期末作业/数据/COR.csv") ggcorrplot(cor_da,type = "lower", lab = TRUE) </pre>
介绍：画原序列图，处理数据实现差分平稳 <pre> Fir_ind<-ts(x1[,1],start=1993) Sec_ind<-ts(x1[,2],start=1993) Thir_ind<-ts(x1[,3],start=1993) X<-data.frame(Fir_ind,Sec_ind,Thir_ind) GDP<-ts(y1[,1],start=1993) X1t<-ts(x1t[,1],start=1993) Ln_GDP=log(GDP) Ln_F_I=log(Fir_ind) Ln_S_I=log(Sec_ind) Ln_T_I=log(Thir_ind) plot(Ln_GDP,type='o',pch=8,col='black',xlab='TIME',ylab='LN_GDP ',main="江苏省 1993-2023 年地区生产总值对数时序图") lines(Ln_F_I,type='o',pch=8,col='blue') lines(Ln_S_I,type='o',pch=17,col='green') lines(Ln_T_I,type='o',pch=20,col='red') legend('topleft',lty=c(1,1,1,1),col=c('black','blue','green','red'), legend=c('Ln_GDP','Ln_F_I','Ln_S_I','Ln_T_I')) </pre>

```

DIF_GDP=diff(Ln_GDP,1)
DIF_F_I=diff(Ln_F_I,1)
DIF_S_I=diff(Ln_S_I,1)
DIF_T_I=diff(Ln_T_I,1)
acf(DIF_GDP)
pacf(DIF_GDP)
install.packages('aTSA')
library('aTSA')
adf.test(DIF_GDP)
adf.test(DIF_F_I)
adf.test(DIF_S_I)
adf.test(DIF_T_I)
for (i in 1:2)
  print(Box.test(DIF_GDP,lag=6*i))
for (i in 1:2)
  print(Box.test(DIF_F_I,lag=6*i))
for (i in 1:2)
  print(Box.test(DIF_S_I,lag=6*i))
for (i in 1:2)
  print(Box.test(DIF_T_I,lag=6*i))

```

介绍：响应序列一元模型 平稳纯随机 建模检验

```

acf(DIF_GDP)
pacf(DIF_GDP)
acf(y_tr)
pacf(y_tr)
y_tr<-window(Ln_GDP,start=1993,end=2017)
#ARIMA
y_fit1<-Arima(y_tr,order=c(1,1,0),include.drift = T)
y_fit1

tsdiag(y_fit1)
t=abs(y_fit1$coef)/sqrt(diag(y_fit1$var.coef))
pt(t,length(y_tr)-length(y_fit1$coef),lower.tail = F)
#arima
y_fit2<-arima(y_tr,order=c(1,1,0))
y_fit2
ts.diag(y_fit2)
t=abs(y_fit2$coef)/sqrt(diag(y_fit2$var.coef))
pt(t,length(y_tr)-length(y_fit2$coef),lower.tail = F)

fore1<-forecast(y_fit1,h=5)
plot(fore1)
lines(fore1$fitted,col=2,lty=2)
test<-window(Ln_GDP,start=2018)

```

```

error1<-test-fore1$mean
file1<-data.frame(fore1$mean,test,error1)
file1
mean(error1)
write_excel_csv(file1, file ="D:/新建文件夹 (5)/大三/时间序列分析/期末作业/数据/file1.csv")
fore2<-forecast(y_fit2,h=5)
plot(fore2)
lines(fore2$fitted,col=2,lty=2)
error2<-test-fore2$mean
file2<-data.frame(fore2$mean,test,error2)
file2
mean(error2)
write_excel_csv(file2, file ="D:/新建文件夹 (5)/大三/时间序列分析/期末作业/数据/file2.csv")
y_fit22<-arima(Ln_GDP,order=c(1,1,0))
y_fit22
fore21<-forecast(y_fit2,h=10)
fore22_<-predict(y_fit22,n.ahead = 5)$pred
ts.diag(y_fit22)
plot(fore21)
write_excel_csv(data.frame(fore22), file ="D:/新建文件夹 (5)/大三/时间序列分析/期末作业/数据/fore22.csv")
plot(fore22)
lines(fore22$fitted,col=2,lty=2)

```

介绍：自变量预测

```

acf(DIF_F_I)
pacf(DIF_F_I)
adf.test(DIF_F_I)
acf(DIF_S_I)
pacf(DIF_S_I)
adf.test(DIF_S_I)
acf(DIF_T_I)
pacf(DIF_T_I)
adf.test(DIF_T_I)

x1_fit<-Arima(Ln_F_I,order=c(1,1,1),include.drift = T)
x1_fit<-arima(Ln_F_I,order=c(1,1,1),transform.pars=F)
x1_fit
ts.diag(x1_fit)
x1_pre<-forecast(x1_fit,h=5)
x1_pre$mean
x2_fit<-arima(Ln_S_I,order=c(1,1,0),transform.pars=F)
x2_fit

```

```

ts.diag(x2_fit)
x2_pre<-predict(x2_fit,n.ahead = 5)$pred
x2_pre
auto.arima(Ln_F_I)
x3_fit<-arima(Ln_T_I,order=c(1,1,0),transform.pars=F)
x3_fit
ts.diag(x3_fit)
x3_pre<-predict(x3_fit,n.ahead = 5)$pred
x3_pre
for (i in 1:2)
  print(Box.test(x1_fit$residuals,lag=6*i))
for (i in 1:2)
  print(Box.test(x2_fit$residuals,lag=6*i))
for (i in 1:2)
  print(Box.test(x3_fit$residuals,lag=6*i))
FOREX<-data.frame(x1_pre$mean,x2_pre,x3_pre)
write_excel_csv(FOREX, file = "D:/新建文件夹 (5)/大三/时间序列分析/期末作业
/数据/FOREX.csv")

```

介绍：LASSO 回归特征选择

```

library(lars)
library(psych)
library(tidyverse)
library(readxl)
y_1<-y1+rnorm(30)
lasso_model <- lars(x1, y_1, type = "lasso")
coef(lasso_model)
coef=coef.lars(lasso_model,mode="step",s=34)
COEF<-data.frame(coef[coef!=0])

```

介绍：多元协整回归模型

```

plot(Ln_GDP,col='black',lwd=2,main="多元时序图")
lines(Ln_F_I,pch=22,col='brown',lty=2,lwd=2)
lines(Ln_S_I,pch=22,col='red',lty=2,lwd=2)
lines(Ln_T_I,pch=22,col='blue',lty=2,lwd=2)
legend("topleft",cex=0.6,lty=2,lwd=2,col=c('black','brown','red','blue'),
      legend=c('Ln_GDP','Ln_F_I','Ln_S_I','Ln_T_I'))
ccf(Ln_GDP,Ln_F_I)
ccf(Ln_GDP,Ln_S_I)
ccf(Ln_GDP,Ln_T_I)
y_fit3<-arima(Ln_GDP,xreg =data.matrix(Ln_S_I,Ln_T_I),include.mean = F)
y_fit3

adf.test(y_fit3$residuals)
Box.test(y_fit3$residuals,lag=6,type = "Ljung-Box")
acf(y_fit3$residuals)

```

```

pacf(y_fit3$residuals)
auto.arima(y_fit3$residuals)
y_fit32<-arima(Ln_GDP,order=c(2,0,0),xreg
=data.matrix(Ln_S_I,Ln_T_I),include.mean = F)
y_estimate<-fitted(y_fit32)
y_fit32#选这个
Box.test(y_fit32$residuals,lag=6,type = "Ljung-Box")
ts.diag(y_fit32)

y_pre<-predict(y_fit32,newxreg=as.matrix(x2_pre,x3_pre),n.ahead = 5)
y_pre
y_fore<-exp(y_pre$pred)
l95<-y_pre$pred-1.96*y_pre$se
u95<-y_pre$pred+1.96*y_pre$se
par(mar = c(5, 5, 4, 2) + 0.1)
par(cex.lab = 1.2, cex.axis = 1.2)
par(las = 1)
plot(Ln_GDP, xlim = c(1993, 2027), ylim = c(8, 12.5), lwd = 2, col = "black", main
= "协整回归动态模型拟合与预测")
lines(y_estimate, col = 2, lty = 2, lwd = 2)
lines(y_pre$pred, col = 2, lty = 2, lwd = 2)
lines(l95, col = "blue", lty = 2, lwd = 2)
lines(u95, col = "blue", lty = 2, lwd = 2)
legend("topleft", legend = c("观测值", "拟合值", "预测值", "置信区间"),
      col = c("black", 2, 2, "blue"),
      lty = c(1, 2, 2, 2),
      lwd = c(2, 2, 2, 2),
      cex = 0.7)

FOREY_X<-data.frame(y_pre$pred,l95,u95,exp(y_pre$pred))
write_excel_csv(FOREY_X, file ="D:/新建文件夹 (5)/大三/时间序列分析/期末
作业/数据/FOREY_X.csv")

```

介绍：ECM 模型

```

library(lars)
DX<-ts(data.frame(DIF_F_I,DIF_S_I,DIF_T_I))
library(aTSA)
ECM<-ecm(DIF_GDP,DX)
write_excel_csv(data.frame(ECM$coefficients), file ="D:/新建文件夹 (5)/大三/时
间序列分析/期末作业/数据/ECM.csv")

```

介绍：随机森林模型

```

install.packages('randomForest')
install.packages('varSelRF')
install.packages('pROC')
library(randomForest)

```

```

library(varSelRF)
library(pROC)
#按 index 拆分训练集与测试集
index <- sample(2,nrow(d),replace = TRUE,prob=c(0.78,0.22))
traindata <- d[index==1,]
testdata <- d[index==2,]
X_t<-data.frame(log(traindata[3:5]))
Y_t<-data.frame(log(traindata[2]))
X_te<-data.frame(log(testdata[3:5]))
Y_te<-data.frame(log(testdata[2]))
#试验性训练模型
test_model <- randomForest(x = X_t[,1:3], y = Y_t[,1])
new_observation <- X_te[,1:3]
prediction <- predict(test_model, newdata = new_observation)
rf_err<-prediction-Y_te[,1]
FINAL<-data.frame(prediction,Y_te[,1],rf_err)
write_excel_csv(data.frame(FINAL), file = "D:/新建文件夹 (5)/大三/时间序列分析/期末作业/数据/FINAL.csv")

```

介绍：协整检验+Granger 因果检验

```

install.packages("lmtest")
library(lmtest)
GF.reg = lm(Ln_GDP~Ln_F_I)
error = residuals(GF.reg)
plot(error,main = "Ln_GDP--Ln_F_I")
adf.test(error)
summary(GF.reg)

GS.reg = lm(Ln_GDP~Ln_S_I)
error2 = residuals(GS.reg)
plot(error,main = "Ln_GDP--Ln_S_I")
adf.test(error2)
summary(GS.reg)

GT.reg = lm(Ln_GDP~Ln_T_I)
error3 = residuals(GT.reg)
plot(error3,main = "Ln_GDP--Ln_T_I")
adf.test(error2)
summary(GT.reg)

acf(DIF_GDP)
grangertest(Ln_GDP~Ln_F_I,order=1)
grangertest(Ln_F_I~Ln_GDP,order=1)#FI 是 GDP 变化原因
grangertest(Ln_GDP~Ln_S_I,order=1)#
grangertest(Ln_S_I~Ln_GDP,order=1)#SI 是 GDP 的因

```

```
grangertest(Ln_GDP~Ln_T_I,order=1)#
grangertest(Ln_T_I~Ln_GDP,order=1)#TI 是 GDP 的因
```

附录 2 代码运行结果

#LASSO 回归选择特征变量

```
> coef=coef.lars(lasso_model,mode="step",s=34)
> coef[coef!=0]
```

第一产业增加值(亿元)	1.003073424	第二产业增加值(亿元)	1.137068409
第三产业增加值(亿元)	1.005507652	工业增加值(亿元)	-0.137039251
建筑业增加值(亿元)	-0.136955726	批发和零售业增加值(亿元)	-0.004014724
交通运输、仓储和邮政业增加值(亿元)	-0.009848287	住宿和餐饮业增加值(亿元)	-0.010885605
金融业增加值(亿元)	-0.006764249	房地产业增加值(亿元)	-0.006462483
其他行业增加值(亿元)	-0.004837538		

#响应序列平稳性检验

```
> adf.test(DIF_GDP)
Augmented Dickey-Fuller Test
alternative: stationary
```

```
Type 1: no drift no trend
      lag    ADF p.value
[1,]    0 -2.294  0.0236

Type 2: with drift no trend
      lag    ADF p.value
[1,]    0 -3.34  0.0242
```

#带漂移项一元序列拟合与参数显著性检验

```
Series: y_tr
ARIMA(1,1,0) with drift
```

Coefficients:

```
      ar1    drift
      0.8061  0.1562
s.e.   0.1483  0.0384
```

```
sigma^2 = 0.00178: log likelihood = 42.46
AIC=-78.92   AICc=-77.72   BIC=-75.38
```

```
> t=abs(y_fit1$coef)/sqrt(diag(y_fit1$var.coef))
> pt(t,length(y_tr-1)-length(y_fit1$coef),lower.tail = F)
      ar1      drift
7.972917e-06 2.380641e-04
```

#不带漂移项一元序列拟合与参数显著性检验

```
Call:
arima(x = y_tr, order = c(1, 1, 0))

Coefficients:
      ar1
    0.9790
s.e.  0.0273

sigma^2 estimated as 0.001725:  log likelihood = 40.7,  aic = -77.41

> t=abs(y_fit2$coef)/sqrt(diag(y_fit2$var.coef))
> pt(t,length(y_tr-1)-length(y_fit2$coef),lower.tail = F)
      ar1
1.12133e-22
```

#输入序列拟合

```
> x1_fit<-arima(Ln_F_I,order=c(1,1,1),transform.pars=F)
> x1_fit

Call:
arima(x = Ln_F_I, order = c(1, 1, 1), transform.pars = F)

Coefficients:
      ar1      ma1
    0.8765  0.5237
s.e.  0.1172  0.1789

sigma^2 estimated as 0.002433:  log likelihood = 44.85,  aic = -83.71

> x2_fit<-arima(Ln_S_I,order=c(1,1,0),transform.pars=F)
> x2_fit

Call:
arima(x = Ln_S_I, order = c(1, 1, 0), transform.pars = F)

Coefficients:
      ar1
    0.9519
s.e.  0.0526

sigma^2 estimated as 0.002996:  log likelihood = 41.92,  aic = -79.84

> x3_fit<-arima(Ln_T_I,order=c(1,1,0),transform.pars=F)
> x3_fit

Call:
arima(x = Ln_T_I, order = c(1, 1, 0), transform.pars = F)

Coefficients:
      ar1
    0.9685
s.e.  0.0347

sigma^2 estimated as 0.00189:  log likelihood = 48.39,  aic = -92.78
```

#Granger 因果检验

```
> grangertest(Ln_GDP~Ln_F_I,order=1)
```

Granger causality test

Model 1: Ln_GDP ~ Lags(Ln_GDP, 1:1) + Lags(Ln_F_I, 1:1)

Model 2: Ln_GDP ~ Lags(Ln_GDP, 1:1)

	Res.Df	Df	F	Pr(>F)
1	26			
2	27	-1	26.205	2.455e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> grangertest(Ln_F_I~Ln_GDP,order=1)#FI是GDP变化原因
```

Granger causality test

Model 1: Ln_F_I ~ Lags(Ln_F_I, 1:1) + Lags(Ln_GDP, 1:1)

Model 2: Ln_F_I ~ Lags(Ln_F_I, 1:1)

	Res.Df	Df	F	Pr(>F)
1	26			
2	27	-1	8.6889	0.00668 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> grangertest(Ln_GDP~Ln_S_I,order=1)#
```

Granger causality test

Model 1: Ln_GDP ~ Lags(Ln_GDP, 1:1) + Lags(Ln_S_I, 1:1)

Model 2: Ln_GDP ~ Lags(Ln_GDP, 1:1)

	Res.Df	Df	F	Pr(>F)
1	26			
2	27	-1	8.2693	0.007942 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

> grangertest(Ln_S_I~Ln_GDP,order=1)#SI是GDP的因
Granger causality test

Model 1: Ln_S_I ~ Lags(Ln_S_I, 1:1) + Lags(Ln_GDP, 1:1)
Model 2: Ln_S_I ~ Lags(Ln_S_I, 1:1)
      Res.Df Df       F    Pr(>F)
1         26
2         27 -1  5.0177 0.03386 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> grangertest(Ln_GDP~Ln_T_I,order=1)#
Granger causality test

Model 1: Ln_GDP ~ Lags(Ln_GDP, 1:1) + Lags(Ln_T_I, 1:1)
Model 2: Ln_GDP ~ Lags(Ln_GDP, 1:1)
      Res.Df Df       F    Pr(>F)
1         26
2         27 -1  7.0042 0.01362 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> grangertest(Ln_T_I~Ln_GDP,order=1)#TI是GDP的因!很明显这个
Granger causality test

Model 1: Ln_T_I ~ Lags(Ln_T_I, 1:1) + Lags(Ln_GDP, 1:1)
Model 2: Ln_T_I ~ Lags(Ln_T_I, 1:1)
      Res.Df Df       F    Pr(>F)
1         26
2         27 -1 22.824 6.047e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#协整回归模型系数
> y_fit3<-arima(Ln_GDP,xreg =data.matrix(Ln_S_I,Ln_T_I),include.mean = F)
> y_fit3

Call:
arima(x = Ln_GDP, xreg = data.matrix(Ln_S_I, Ln_T_I), include.mean = F)

Coefficients:
      data.matrix(Ln_S_I, Ln_T_I)
                    1.0720
s.e.                    0.0013

sigma^2 estimated as 0.004545:  log likelihood = 38.34,  aic = -72.68
#协整模型显著性检验
> Box.test(y_fit3$residuals,lag=6,type = "Ljung-Box")

Box-Ljung test

data:  y_fit3$residuals
X-squared = 75.569, df = 6, p-value = 2.931e-14

```

```

Call:
arima(x = Ln_GDP, order = c(2, 0, 0), xreg = data.matrix(Ln_S_I, Ln_T_I), inc

Coefficients:
          ar1          ar2  data.matrix(Ln_S_I, Ln_T_I)
      1.5016   -0.5742                1.0720
s.e.   0.1508    0.1514                0.0042

sigma^2 estimated as 0.000316:  log likelihood = 76.73,  aic = -145.45
> Box.test(y_fit32$residuals, lag=6, type = "Ljung-Box")

      Box-Ljung test

data:  y_fit32$residuals
X-squared = 3.082, df = 6, p-value = 0.7985

#输入序列纯随机性检验
> for (i in 1:2)
+   print(Box.test(DIF_F_I, lag=6*i))

      Box-Pierce test

data:  DIF_F_I
X-squared = 14.333, df = 6, p-value =
0.02613

> for (i in 1:2)
+   print(Box.test(DIF_T_I, lag=6*i))

      Box-Pierce test

data:  DIF_T_I
X-squared = 17.105, df = 6, p-value =
0.008904

> for (i in 1:2)
+   print(Box.test(DIF_S_I, lag=6*i))

      Box-Pierce test

data:  DIF_S_I

```

```
X-squared = 20.607, df = 12, p-value = 0.05645
```

```
#ECM 模型参数
```

```
> ECM<-ecm(DIF_GDP,DX)
```

```
Call:
```

```
lm(formula = dy ~ dX + ECM - 1)
```

```
Residuals:
```

	Min	1Q	Median	3Q	Max
	-0.0071973	-0.0010834	0.0002445	0.0014351	0.0031360

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
dXDIF_F_I	0.09364	0.01076	8.702	6.89e-09 ***
dXDIF_S_I	0.52966	0.01329	39.840	< 2e-16 ***
dXDIF_T_I	0.37580	0.01627	23.104	< 2e-16 ***
ECM	-0.27516	0.14313	1.922	0.0665 .

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.002656 on 24 degrees of freedom
```

```
Multiple R-squared:  0.997,    Adjusted R-squared:  0.9965
```

```
F-statistic: 2022 on 4 and 24 DF, p-value: < 2.2e-16
```