

江南大学

《数据分析及应用》 大作业

题目： 基于图数据挖掘的无锡地铁
网络分析与特征工程

理 学 院 信息与计算科学 专 业

学 号 _____

学生姓名 朱敏

任课教师 _____

二〇二四年一月

摘 要

图论在生物信息学、交通网络设计等多个方面有着广泛的研究与应用价值。本文通过无锡地铁数据，构建地铁交通网络图，并对其进行数据挖掘与特征选择。

图数据挖掘对传统图机器学习有着基石般的作用。由图数据挖掘所得特征矩阵或特征向量作为输入，再训练得到机器学习模型，模型的有效性直接决定于所选取特征的优劣性、适用性。

网络分析方面，本文在建立地铁导航系统时，从地铁网络图的连通性、图的最短距离逐步分析应用。将实际问题转化为图论问题，运用 Dijkstra 等图论经典算法解决实际问题。在对地铁网络图进行特征选择时，得出对单幅地铁网络图，适用于节点层面的特征的结论。

根据节点特征选择所得结论有：节点度中心性取值相对固定，可直观看出换乘站点；特征向量中心性和介度中心性以“无锡火车站”和“三阳广场站”为中心向四周辐射，前者可反映经济与城市发展状况，后者可反映城市人流量；接近度中心性整体数值较高，对未来共享交通的建设有借鉴意义。

关键词：图论 数据挖掘 地铁网络 特征选择 网络分析

一、引言

图论作为数学的一个分支，在计算机科学、运筹学、网络分析等多个领域都存在着广泛的应用与研究价值。在计算机科学中，图论被用于网络建模、算法设计、数据结构等方面；在运筹学中，图论有交通网络设计、路径规划等应用；在网络分析领域，图论可用于研究社交网络分析、生物信息学等方向^[1]。

近年来，机器学习技术迅猛发展，非结构化的图数据信息通过图数据挖掘等方法应用拓展形成图机器学习分支。目前图机器学习可被分类为传统图机器学习与基于深度学习的图机器学习。其中传统图机器学习是指需要人工进行图数据的特征选择，再将其输入机器学习算法中预测的方法；而基于深度学习的机器学习通过图神经网络等深度学习方式自动学习得出特征，并构建机器学习模型实现预测。

课程中丁老师以生物信息学为例，介绍了图论在蛋白质研究方向的应用。如以氨基酸为节点，氨基酸之间的相互作用为边进行蛋白质结构的预测、通过蛋白质相互作用的拓扑网络实现蛋白质功能的识别以及研究蛋白质与药物分子之间的互相作用来设计药物等。其中对蛋白质特征的选择是进行后续研究的关键与基石。本文通过无锡地铁数据，构建地铁交通网络图，并对其进行数据挖掘与特征选择。

二、地铁交通网络图的构建

2.1 数据

2.1.1 数据来源

本文数据来源于无锡地铁官方网站(<http://www.wxmetro.net/>)。包含地铁线路导览与列车时刻表。

2.1.2 数据处理

图的基本组成要素是节点与边，在进行地铁网络图构建时，以站点为节点，站点间的前后站关系为边，构造双向图。此外，每条边的属性还有线路号与运行时间。由于地铁运行是双向运行，前后站关系具有相对性，所以相邻两个节点需要正向与反向两次输入。根据原始数据，将所需要的信息截取整合至表格中，以便后续图的建立。

2.2 地铁交通网络图的构建

基本的边与节点关系建立完成后，在将地铁网络图可视化时，发现其呈现不规则状。为真实拟合地铁网络分布，在原图基础上为每个节点设置相对坐标，并根据边的“地铁线”属性在绘图时赋予不同的颜色，最终构建出的地铁交通图如下：



图 1：无锡地铁线路图




图 2：构建地铁网络图

三、基于地铁交通网的数据挖掘

3.1 网络分析

3.1.1 理论分析

连通性：应用图论知识，可以对地铁交通网络图进行网络分析。网络图中的节点对应站点，边对应前后站关系。想要知道某两站间是否存在可行的线路，则对应于图论中的连通性。若站点间是可达的，在图中表示为两节点间是连通的。城市地铁网图通常情况下均为连通图，即任意两个站点间至少存在一条路径。实际应用中连通性是评估地铁网络完整性的重要指标。

最短距离：由于地铁线路间存在多个“枢纽站点”，即网络图中连接多条边的关键节点，节点间线路往往存在多条，此时就需要对路线进行选择。将两个站点间花费的时间作为边的权重，地铁线路选择问题就转化成了图论中的最短路径问题。

导航系统：地铁导航系统需要实现任意输入两个节点，能得到它们的最短路径，并显示出最短路径中的所有站点，对用户做出指引。这里最短路径的获取可以使用图论中经典的 Dijkstra 算法等。

3.1.2 实际应用

在具体实现时，用到 NetworkX 库来实现对复杂网络的创建、分析与可视化。

例如需要建立“江南大学站”到“吴桥站”的导航系统，根据地铁线路图，可以得知自江南大学到吴桥至少有两条线路，分别是自江南大学乘坐 1 号线直至无锡火车站，

换乘 3 号线到达吴桥；以及自江南大学乘 1 号线到市民中心站换乘 4 号线至盛岸站，再换乘 3 号线到达吴桥。且两条线路在路线长度上相近，仅凭线路图无法知晓哪种路径较快。

若仅根据我们构建的地铁网络图，对于导航系统，首先需要确定两个节点间是否连通，然后用算法计算得出最短路径，最后遍历最短路径，得到导航结果信息如下：

表 1：导航结果

路线	线路	时间
江南大学--->文化宫	1 号线	2.0 分钟
文化宫--->市民中心	1 号线	3.0 分钟
市民中心--->周新苑	4 号线	2.0 分钟
周新苑--->五湖大道	4 号线	2.0 分钟
五湖大道--->大剧院	4 号线	2.0 分钟
大剧院--->蠡湖大桥	4 号线	2.0 分钟
蠡湖大桥--->夏家边	4 号线	3.0 分钟
夏家边--->体育中心	4 号线	3.0 分钟
体育中心--->西园弄	4 号线	3.0 分钟
西园弄--->河埭口	4 号线	2.0 分钟
河埭口--->青山湾荣院	4 号线	2.0 分钟
青山湾荣院--->惠山古镇	4 号线	2.0 分钟
惠山古镇--->盛岸	4 号线	3.0 分钟
盛岸--->吴桥	3 号线	3.0 分钟
共计		34 分钟

3.2 特征工程

3.2.1 理论分析

图信息的三个层面是节点信息，连接信息和全图信息，由于图信息是非结构化的，将其作为图机器学习的输入时，需要对以上三个层面的信息进行特征提取，将信息转化为能被计算机识别的矩阵或向量形式。多个样本三个层面的特征向量共同构成了训练集，将其输入机器学习算法，训练得到机器学习模型，即能预测陌生样本的类型。

但节点、连接、全图蕴含的特征是复杂多样的，训练得到模型的效率很大程度上决定于输入的特征。如何从繁多的特征中选择对类型判别最有效的特征，就是图数据挖掘中的特征工程。

图数据挖掘的特征工程中，更注重节点、边、子图在整个群体中的作用，即更注


重它们的结构信息、连接特征。节点层面，有如下常用特征^{[2][3]}：

- (1) 节点度中心性 (Degree Centrality)：表示图中与某节点直接相连的边的数量，衡量节点在网络中的连接程度。
- (2) 特征向量中心性 (Eigenvector Centrality)：表示节点在网络中的重要程度，而不仅只看连接数量。如果一个节点周围的节点重要程度高，那么该节点也很重要。
- (3) 介度中心性 (Betweenness Centrality)：表示图中某节点在网络中作为桥梁的程度，即是否是传输的必经之地。如马六甲海峡等重要交通枢纽，介度中心性高。
- (4) 接近度中心性 (Closeness Centrality)：衡量节点到其他节点的平均距离，反映了节点在网络中的可及性。

图数据特征工程的连接层面指由已知连接的特征补全未知连接，如社交网络中“可能认识的人”，由于地铁网络图中连接代表前后站关系，是客观存在的，所以不存在连接层面的特征。全图层面的特征工程是对整个网络图提取特征作为输入，由于本文只研究了无锡一座城市的地铁网络，不具备多个全图作为训练集，故也不适用。所以对地铁网络图的特征工程主要研究节点层面。

3.2.2 实际应用

分别对所构建地铁网络图中的节点计算节点度中心性、特征向量中心性、介度中心性和接近度中心性。






图 3：地铁网络图节点特征结果

比较四幅中心性可视化图，由图(a)可知节点度中心性取值相对固定，只有线路交叉处的节点有较高的值，由此图可直观看出来换乘站点。

图(b)的特征向量中心性表示节点重要程度，有图可知，节点重要性以“无锡火车站”和“三阳广场”为中心向四周辐射，越接近中心，取值越高。此数值一定程度上反映了城市发展与中心城区情况，对城市规划、房地产、投资等领域都有参考意义。

图(c)的介度中心性总体与图(b)相似，符合实际中“无锡火车站”这一节点作为交通枢纽的情况，由此图可以推断人流量的多少。

图(d)接近度中心性整体数值都较高，体现了无锡地铁总体可达性都较高，地铁规划合理。在未来新建地铁线路时，此值可作借鉴。

四、 结论

对具有普遍关系的数据，可将关系作为边，数据本身作为节点，构建图，运用图论知识与算法解决实际问题。在创建复杂网络时，需要注重图的有向性等性质，对原数据做出相应处理。

图数据挖掘对传统图机器学习有着基石般的作用。通过网络分析与特征选择，能对所构建的图有更深刻的认知。本文在建立地铁导航系统时，就是从地铁网络图的连通性、图的最短距离逐步分析形成的应用。在对地铁网络图进行特征选择时，得出对单幅地铁网络图，适用于节点层面的特征的结论。

节点度中心性取值相对固定，可直观看出换乘站点；特征向量中心性和介度中心性以“无锡火车站”和“三阳广场”为中心向四周辐射，前者可反映经济与城市发展状况，后者可反映城市人流量；接近度中心性整体数值较高，对未来共享交通的建设有借鉴意义。

五、参考文献

- [1] 李明德. 图机器学习在网络安全大数据分析中的应用[D]. 华东师范大学, 2023. DOI:10.27149/d.cnki.ghdsu.2023.001695.
- [2] Newman, Mark. Networks: An Introduction (pp. 168-234, Chapter 7: Measures and Metrics)., Oxford University Press, 2010.
- [3] Zachary, Wayne W. An Information Flow Model for Conflict and Fission in Small Groups., 1977.

六、附录

附录 1
实现代码及结果
见附件