

聚类分析实验报告

姓名：■■■

学号：■■■■■■■■■■

班级：■■■■■■■■

实验目的：

- 使用 SPSS 或 R 软件实现聚类分析。

实 验 环 境: SPSS、R

实验内容： 能根据数据文件进行系统聚类以及 K—均值聚类法，并能根据聚类结果进行比较分析。

实验数据： EXCEL 文件

1 数据表 1 为 15 家上市公司 2001 年的一些主要财务指标，使用系统聚类法和 K—均值法分别对这些公司进行聚类，并对结果进行比较分析。

系统聚类法：

聚类过程：

表 1

聚类次数	类	类
[1,]	-10	-12
[2,]	-9	1
[3,]	-7	2
[4,]	-11	3
[5,]	-2	-6
[6,]	-4	4
[7,]	5	6
[8,]	-5	7
[9,]	-15	8
[10,]	-8	9
[11,]	-3	10
[12,]	-1	11
[13,]	-14	12
[14,]	-13	13

在系统聚类过程中，由聚类过程表可知，公司 10 和 12 最先被聚为一类，然后公司 9、7、11 按次序加入这个组合后的新类，公司 2 和公司 6 聚成一类后继续加入这新类，公司 4 加入后，公司 5 和 6 聚成一类，加入新类，公司 15, 8, 3, 1, 14, 13 相继加入，最终聚成一个类。

以上过程用图可表示为：




图 1

根据图像，可以分析得到聚成两类较为合适，即公司 13 为一类，其余 14 个公司为一类。

K—均值法：

K 均值聚类法各公司距离标准化后的距离阵图像示意如下：




图 2

根据图像可以明显看出，第 13 家公司相对其他公司的距离颜色深，距离大，差异明显，而另外 14 家公司相互间距离都不大，故可初步判断聚成两类较为合适。

接着，绘制碎石图确定最佳分类数目，图像如图（3）。

可以看出，聚类数目为 2 前后出现明显的趋势不同，最终确定 K 均值聚类类别为 2。

将聚类结果可视化（图（4））可以看出，两个类间有明显差异，类内较为聚集，聚类效果好。




图 3：K-MEANS 碎石图




图 4：聚类结果可视化

2 数据表 2 为第四次经济普查中，按地区、行业门类分组的法人单位数（来自于国家统计局网站）。试选取合适的方法对数据进行聚类分析。

问题分析：

本题数据样本数和变量数都较大，需要在聚类分析前对数据进行预处理，降低数据复杂度。再对处理后的数据进行 K-均值聚类，找出再产业类型上具有相似特征的省份。

问题实现：

首先对行业数据进行相关性分析，计算各行业间相关性得到行业相关性矩阵可视化如下：




图 5：行业相关性图（预处理前）




图 6：行业相关性图（预处理后）

可以看出，许多行业间相关性程度很高，如果全部保留，会增加数据冗余度。于是，对相关程度高于 95% 的行业进行筛选，在两行业间只留下一个作为代表。经此筛选，删去的行业有：制造业，交通运输、仓储和邮政业，信息传输、软件和信息技术服务业，居民服务、修理和其他服务业，房地产业，科学研究和技术服务业、批发和零售业。对余下的农、林、牧、渔业，采矿业，电力、热力及燃气及水生产和供应业，建筑业，住宿和餐饮业，金融业，租赁和商务服务业，水利、环境和公共设施管理业，教育，卫生和社会工作，文化和体育，

公共管理等行业进行保留，并依此数据聚类。

根据筛选后行业相关图可以看出，行业间相关程度均已低于 95%，数据冗余度大大降低。

使用 K-均值聚类方法，先对数据进行标准化处理，接着计算其欧氏距离，绘制碎石图确定最佳分类数目，从碎石图可看出，1-2、2-3 与 3-30 的趋势存在明显不同，所以分为三类较为合适。

问题结果：




图 6：碎石图

由最终聚类结果可知，广东省、浙江省、江苏省、山东省、河南省为一类；北京市、重庆市、福建省、安徽省、湖北省、四川省、河北省、湖南省、山西省、陕西省、江西省、辽宁省、云南省、广西省、内蒙古、贵州省为一类；上海市、天津市、吉林省、海南省、青海省、甘肃省、黑龙江省、新疆省、西藏省、宁夏省为一类。



图 7：聚类结果可视化

[附：实验代码]

实验 1

```
library(readxl)
d<-read_excel("D:/新建文件夹 (5)/大三/多元统计/数据/聚类分析数据.xls",1)
rn<-d$公司
df<-d[, -1]
df<-scale(x=df)
dis<-dist(df,method="euclidean")
result<-hclust(d=dis,method="centroid")
plot(result,labels=rn)
result$merge

library(tidyverse)
library(cluster)
library(factoextra)
fviz_dist(dis,gradient=list(low='white',high='red'))
wss<-function(k){
  kmeans(df,k,nstart=10)$tot.withinss
}
k.values<-1:14
wss_value<-map_dbl(k.values,wss)
plot(k.values,wss_value,
     type='b',pch=19,frame=FALSE,
     xlab="Number of K",
     ylab="Total within-clusters of squares")

k2<-kmeans(df,centers=2,nstart=10)
fviz_cluster(k2,data=df)
```

实验 2-行业相关性分析

```
library(readxl)
library(tidyverse)
library(ggcorrplot)
Sys.setlocale(category="LC_ALL",locale="zh_CN.UTF-8")
d<-read_excel("D:/新建文件夹 (5)/大三/多元统计/数据/聚类分析数据.xls",5)
#nms<-d$法人单位数.个.
nms<-d[,1]
# 提取每行的第一个汉字
first_characters <- substr(nms[3:15], 1, 2)
d<-d[, -3]
d<-data.frame(d)
options(digits = 2)
da<-na.omit(d)
da<-da[, -1]
dat<-da[, -2]
```

```

dat=as.data.frame(lapply(dat,as.numeric))
names(dat)<-c(first_characters)
cor_df<-cor(dat[2:14])
ggcorrplot(cor_df,type = "lower", lab = TRUE)

```

实验 2-聚类分析

```

library(readxl)
d<-read_excel("D:/新建文件夹 (5)/大三/多元统计/数据/聚类分析数据.xls",5)
rn<-d$地区
df<-d[,-1]
df<-scale(x=df)
df<-na.omit(df)
row.names(df)<-rn
dis<-dist(df,method="euclidean")

library(tidyverse)
library(cluster)
library(factoextra)
fviz_dist(dis,gradient=list(low='white',high='red'))
wss<-function(k){
  kmeans(df,k,nstart=10)$tot.withinss
}
k.values<-1:30
wss_value<-map_dbl(k.values,wss)
plot(k.values,wss_value,
type='b',pch=19,frame=FALSE,
xlab="Number of K",
ylab="Total within-clusters of squares")

k2<-kmeans(df,centers=3,nstart=10)
fviz_cluster(k2,data=df)

```