


实验名称 实验4 基因表达数据分析

一、实验内容及结果


1. 安装 treeview (<http://jtreeview.sourceforge.net/>), 显示 GSE226866 的聚类结果, 并对三种算法的结果进行比较。 #三种算法
- 2.对 data 文件夹中的 GSE183947_fpkm.csv 数据进行聚类。 #sklearn

结果 (截图):


Task1:



K-means



系统聚类



SOM

结果比较：

以上三种方法都对每行的基因和每列的不同环境下的样本分别进行了聚类。

K-means 方法需要自己设置最终聚类的类数，这里我们通过设置 `n_cluster` 把基因聚成 5 类，样本聚为 2 类；系统聚类最终把所有节点聚成一类，但可以在系统聚类完成后对树进行剪枝，以获得自己想要的类别数；

SOM 是根据拓扑结构对节点进行聚类。

观察三种方法的聚类图像，系统聚类方法通过上方和左侧的连接展示了所有样本逐渐聚为一个大类的过程。聚类图像中红色代表基因表达水平较高，黑色则表示表达水平较低。观察结果可知，**K-means 方法和系统聚类图像红色和黑色区域界限较分明**，红色和黑色各自形成一个大区域，意味着算法倾向于把表达水平高的基因聚为一类，表达水平低的聚为了另一类。而 **SOM 方法图像中黑色和红色是穿插的**，在聚类时基因表达水平可能不是主要区分指标。

Task2:


使用 scikit-learn 中的 K-means 方法对 GSE183947_fpkm 的基因进行聚类。聚为 3 类时各项评价指标较优良。

在选取评价指标时, 不能通过类别越多数值越小的指标来判断聚类效果, 如类内距离平方和。故选取 silhouette_score, 发现其聚为 2、3 类时效果最好, 这里选取 3 类。

```
for n_clusters in [2,3,4,5,6]:
    cluster = KMeans(n_clusters=n_clusters, random_state=0).fit(x_f)
    y_pred = cluster.labels_
    # calinski_harabasz_score(X, y_pred)
    # print(n_clusters, ",", calinski_harabasz_score(X, y_pred))
    silhouette_score(x_f, y_pred)
    print(n_clusters, ",", silhouette_score(x_f, y_pred))
```

```
2 , 0.9991870699410533
3 , 0.9608190953997855
4 , 0.9294398925166572
5 , 0.9159872319193242
6 , 0.9160051828314442
```

考虑到原始数据有 60 列, 尝试对原始数据进行降维。使用 PCA 方法降维时发现, 只需二维数据即可保存原始数据的 97% 的信息, 故对原数据进行 PCA 降维, 设置类别数为 3, 可视化图如下。



原始数据分类结果如下：

```
Cluster 0:
      CA.102548 CA.104338 CA.105094 CA.109745 CA.1906415 CA.1912627 \
0      0.93      1.97      0.00      5.45      4.52      4.75
1      0.00      0.00      0.00      0.00      0.00      0.00
2      0.00      0.43      0.00      3.43      8.45      8.53
3      5.78      5.17      8.76      4.58      7.20      6.03
4      2.83      6.26      3.37      6.24      5.16      13.69
...      ...      ...      ...      ...      ...
20241      0.00      0.16      0.00      0.00      0.00      0.30
20242      0.00      0.00      0.00      0.00      0.00      0.00
20243      0.00      0.00      0.00      0.83      0.00      0.00
20244      0.00      0.00      0.00      0.10      0.64      0.00
20245      0.00      0.00      0.00      0.00      0.00      0.00

[20139 rows x 61 columns]
```

```
Cluster 1:
      CA.102548 CA.104338 CA.105094 CA.109745 CA.1906415 CA.1912627 \
12136      62862.4      92774.67      3261.36      40052.57      57433.09      45745.88

      CA.1924346 CA.1926760 CA.1927842 CA.1933414 ... CAP.2046297 \
12136      78572.24      40829.4      34438.46      33930.11      ...      36781.2

      CAP.2046641 CAP.348981 CAP.354300 CAP.359448 CAP.94377 CAP.98389 \
12136      50243.67      36869.18      17370.96      38829.42      17267.71      37100.21

      CAP.98475 CAP.99145 Cluster
12136      15842.07      77660.46      1

[1 rows x 61 columns]
```

```
Cluster 2:
      CA.102548 CA.104338 CA.105094 CA.109745 CA.1906415 CA.1912627 \
264      52.010      94.220      166.635      200.530      237.740      274.355
301      82.860      72.170      15.930      170.030      382.270      185.990
394      330.250      224.720      75.190      475.850      1055.470      522.610
452      442.440      240.040      34.400      820.540      992.010      588.000
510      306.980      566.220      68.280      438.760      622.750      421.610
...      ...      ...      ...      ...      ...
18737      2539.770      1749.210      6803.090      543.200      210.890      224.340
18754      216.420      215.020      27.670      551.360      530.980      1192.010
18906      4.985      10.895      10.895      24.385      39.555      90.000
19025      7.730      45.185      45.185      71.095      80.500      94.680
19320      105.050      91.670      3.140      624.240      331.570      294.910

[106 rows x 61 columns]
```

可以发现在此聚类方法下，大部分样本都集中在类别 0 中，类别 1 中只有一个基因。