



江南大学

《生物信息学概论》大作业

题目：基于机器学习的基因表达数据分析
的研究进展

班 级 _____

学 号 _____

姓 名 _____

一、 基因表达数据分析（15 分）

基因表达数据是什么：

基因表达数据是指通过生物技术手段测量和记录基因在特定条件下的表达水平的数据。这些数据反映了不同生理状态下基因表达过程中基因转录产物 mRNA 在细胞中的丰度，也就是在不同细胞类型、组织、时间点或实验条件下，各基因被转录成 mRNA 的程度。

基因表达数据的类型主要包括 cDNA 微阵列（cDNA microarray）、转录组测序技术（RNA-seq）、基因表达系列分析（SAGE）、逆转录聚合酶链式反应（RT-PCR）等。其中基因微阵列数据的两种形态分别是基因-实验条件数据和样本-基因表达数据。

基因表达矩阵通常是一个扁平的数据集，因为相较于样本数量，特征数量非常高，这造成了基因表达数据“高维度、少样本”的特点，也是由于这个特点，需要后续对基因表达数据进行降维、特征选择等操作。

基因表达数据的聚类分析：

对基因表达数据的聚类是一种无监督学习方法，它根据样本或基因数据的相似性或距离把它们划分为不同的类别，来发现可能具有相似功能或参与相似生物学过程的基因群体。聚类算法可以分为基于基因的聚类、基于样本的聚类和双向聚类（同时考虑基因和样本）。

基因表达数据的聚类分析在癌症诊断、基因功能预测、疾病亚型的发现等多个方面有重要应用：聚类分析可以将基因表达数据中具有相似表达模式的基因分组在一起，通过比较突变或异常表达的基因，能识别出肿瘤细胞与正常细胞之间的差异信息，实现癌症诊断；根据结构相似的基因具有相似的功能这一猜想，被可以通过同类已知基因预测未知基因的功能；对聚类后的基因表达数据进行差异化分析，能获知新的疾病亚型。

基因表达数据的分类分析：

分类算法属于监督学习方法，它通过已知标签的训练数据来构建模型，并将该模型应用于新的、未知的数据上，以预测它们的类别。

二分类的应用有临床研究中的病例识别、疾病诊断、细胞状态分类等，如判断细胞处于高表达状态还是低表达状态、区分正常组织与癌症组织等；多分类的应用有对疾病的分级和分期、细胞类型鉴定、识别癌症亚型等，如对疾病处于早期、中期、晚期的判断等。

二、 基因表达数据分析中的机器学习方法（20 分）

机器学习方法的出现为基因表达分析开辟了新维度，它对分析基因表达数据、挖掘数据内部蕴藏的信息有很大作用。在对基因表达数据分析的研究中，常用的机器学习方法大致可以分为四类：监督学习、无监督学习、半监督学习和深度学习，每个类别在数据分析和挖掘的过程中都有其适用的情形。

监督学习：

监督学习是指在已知标签的数据上训练模型，使模型能够从特征中学习得到标签的模式，并预测新数据的标签。根据标签是定量还是定性的，又可以将监督学习的任务分为分类和回归。在分类问题中，数据样本被划分到标签的有限类别中；在回归问题中，模型函数将数据映射到实值变量，对于每个新样本，可以对其估计预测变量的值。基因表达数据分析时常用的监督学习算法有：

1. 支持向量机（SVM）：

SVM 通过在高维空间中找到一个最佳的分离超平面，将不同类别的样本最大化地分开。它可以处理线性不可分的问题，通过使用核函数将数据映射到更高维空间。

2. 随机森林（RF）：

随机森林是一种基于决策树的集成方法，通过构建多个决策树并结合它们的预测结果，来提高分类或回归的准确性和稳定性。每棵树在训练时都会选择数据的一个随机子集和特征的一个随机子集。

3. K-近邻算法（K-NN）：

K-NN 是一种基于实例的学习算法，通过计算新样本与训练样本的距离，找到最近的 k 个邻居，并以多数邻居的标签作为新样本的预测标签。

无监督学习：

无监督学习是在没有标签的数据上进行训练，用于训练的样本不具有类别标签等先验信息，算法希望从数据本身发现它们的内在结构、模式或特征分布，并发掘相似样本间的模式或簇。聚类是一种常见的无监督任务，通过聚类，每个新样本被分配给所识别出的集群之一，这些集群样本内部共享某些相似特征。常用的无监督学习算法有：

1. K-means 聚类：

K-means 聚类将数据分为 k 个簇，通过迭代地分配数据点到最近的质心，并更新质心的位置，直到簇内距离最小化。

2. 层次聚类：

层次聚类通过逐步合并或分裂数据点形成树状结构，展示数据的层次关系。它不需要预先指定簇的数量。

3.主成分分析（PCA）：

PCA 通过线性变换将高维数据投影到低维空间，保留数据的主要变异信息，从而简化数据并去除噪声。

半监督学习：

半监督学习是监督学习和无监督学习的结合。在半监督学习中，有标签数据和无标签数据都被用于模型构建，以充分利用各类数据实现更准确的预测。在实际应用中，由于数据标记过程繁杂易错、成本高昂，大部分数据都没有标签，有标签的数据只占很少部分。通过半监督学习方法，模型能高效利用大量无标签样本和少量有标签样本，最大化已知信息的利用。常用的半监督学习算法有：

1、半监督自编码器（SSAE）：

半监督自编码器利用自编码器的结构，通过对输入数据进行编码和解码，学习其潜在特征表示。在半监督学习的框架下，SSAE 使用有标签的数据进行监督训练，同时利用大量无标签的数据进行无监督训练，从而在特征表示和分类任务中都能受益。

2、图半监督学习：

图半监督学习利用样本之间的相似性构建图结构，将有标签和无标签样本表示为图上的节点，通过图的连通性传播标签信息，实现分类或回归任务。

深度学习：

深度学习基于人工神经网络，通过模仿人脑的结构和功能来进行数据处理和分析。常用的深度学习算法有：

1、卷积神经网络（CNN）：

尽管 CNN 主要用于图像处理，但其变种也可用于序列数据，如基因表达数据，以识别基因序列中的模式。

2、循环神经网络（RNN）：

RNN 能够处理序列数据的时间依赖性，适用于动态的基因表达变化分析。

3、自动编码器（AE）：

AE 通过数据的压缩表示和重构来学习数据的有效特征表示，它能够从数据中学习到一种紧凑且有效的表示形式，有助于后续对数据的进一步分析。

除了以上根据有无标签进行的分类，在基因表达数据分析中，单个算法与集成算法也是常被考虑的两个方面。单个算法是指独立运行的单一模型，而集

成算法以单一算法为基模型，用不同的集成方式组合它们，来提高整体模型性能和鲁棒性。常用的集成方法有 Bagging、Boosting、Stacking。

三、 基于机器学习的基因表达数据分析综述（50 分）

由于机器学习算法及其创新种类繁多，在本段综述中我采取按应用分类的方式，针对基因表达数据分析中的不同应用，归纳涉及的机器学习算法。阅读相关文献后，我发现对基因表达数据分析的研究通常涵盖两个类别的任务。一是对基因表达数据具体数据处理技术的研究，包括填补缺失值、降维与特征选择、关键基因识别等，这类研究侧重于改进数据处理技术，以提高后续分析的准确性与可靠性。另一类是生物信息学范围上更广义的应用，如癌症诊断分类、预后预测、生物标志物发现与新类识别等，这类研究旨在运用基因表达数据解决实际生物学问题。这两类任务的研究并不是相互独立的，而是相辅相成的。具体的数据处理为广义的生物学应用提供了优良的数据基础，而广义生物学应用的深入也驱动了更先进数据处理技术的需求与发展。^[1]

这两类任务的研究中都大量运用了机器学习方法，下文选取了典型应用及涉及的机器学习方法进行综述。

填补缺失值：

在收集基因表达数据时，如点样不均匀、不适当的手动操作、芯片表面污染等操作常常会导致基因微阵列实验收集的数据存在缺失。而完整准确的数据是训练性能良好的模型的基础，所以对基因表达谱数据的缺失值填补是非常必要的预处理操作。

传统的机器学习算法只基于局部信息或全局信息填补缺失值。如 KNNimpute 基于局部信息考虑了近邻的 K 个基因的表达数据；SVDimpute 在进行缺失值的填补时利用全局信息，通过奇异值分解找到支撑向量，然后进行缺失值的估计。^[2]然而无论是局部信息还是全局信息，都存在填补精度上的欠缺。

近年来的研究主要集中在结合局部学习方法和全局学习方法的混合填补方法上，以及运用更复杂、更综合的机器学习方法。韩旭^[3]（2019）运用了集成学习的 Stacking 思想，结合 K-近邻填补和最小二乘法等传统机器学习方法，兼顾了局部和全局信息，得到了较为准确的填补结果。

Yeping Lina Qiu, Hong Zheng 等人^[4]（2020）用基于变分自动编码器

(VAE) 的深度学习框架进行基因组缺失值填补，并证明了其在转录组和甲基化组数据分析中的有效性。

降维与特征选择:

由于基因表达数据“高纬度、少样本”的特性，其在构建模型时通常会导致信息稀疏，为了减少冗余信息，高效利用数据，需要从基因表达数据的众多特征中进行降维和选择。在基因表达数据分析中，特征选择的过程也可以称作选择关键基因的过程。

根据特征选择过程与算法学习过程是否独立，特征选择方法大致可以分为四类：过滤方法、包装方法、嵌入方法和混合方法。针对基因表达数据特征维度高而样本数量少造成的不匹配问题，肖雅雯^[5]（2020）提出了基于堆栈稀疏自动编码器（SSAE）的半监督深度学习癌症诊断方法，提取出了更抽象和有代表性的特征，属于嵌入方法；刘健^[6]（2019）提出一种监督型惩罚矩阵分解算法，从而对特征基因进行选择，他的研究结合了深度学习、稀疏滤波、最优均值算法、分块优化理论和监督型惩罚矩阵分解算法等多种技术和理论，属于混合方法；李胜斌^[7]（2022）考虑了特征基因之间的作用关系，先从基因表达谱数据集中筛选出关键基因，再寻找关联性强的特征并进行全局优化，其方法也属于混合方法；张晶^[8]（2022）比较了三种典型的过滤式、组合式、嵌入式算法，得出 k-split-Lasso 特征选择算法筛选出的基因集判别样本类别的效果最好；张陆星^[9]（2021）提出了一种新的基于 PCA 的鲁棒拉普拉斯监督判别稀疏主成分分析（RLSDSPCA）并验证其取得了最佳性能。

总结特征选择中机器学习算法的发展态势，发现其总体呈现以下共性特点：多阶段特征选择的趋势，即初步筛选与精细筛选相结合；多模型评估特性，使用多种分类器对特征选择的效果进行评估，确保选出的特征在不同模型中都有良好的表现；混合算法被广泛使用，混合方法是两种或多种过滤器与包装器方法的组合，因其能降低错误率并减小过拟合风险的特性被更多地使用。

类别判断:

类别判断属于机器学习的分类范畴，是对基因表达数据进行分类或系统地排列成不同类别。用于类别预测的传统机器学习算法有 K 近邻算法、决策树算法、SVM 算法等。

其在生物学中的应用之一是识别癌症的亚型。张佳航^[10]（2020）运用了基于 GeneRank 分数与 SVM、RF、KNN 分类器特征权重结合的机器学习方法对非小细胞肺癌的基因表达数据进行了分析和研究，提出了 WGRFE 算

法，成功区分了肺腺癌和肺鳞癌两种亚型；李少川^[11]（2022）提出了一个基于癌症亚型特异性基因的深度学习模型来识别癌症亚型，后又对其改进提出了一个自然启发式自动深度学习机，并验证了这两种框架都可以优选出癌症亚型的关键性基因。

疾病早期诊断是类别预测的另一实际应用。杨磊^[12]（2020）提出了一种针对基因表达数据分类的代价敏感旋转森林算法，克服了基因表达数据分布不平衡的特性，并验证该算法可以在保证分类精度的基础上有效降低分类代价；张强^[13]（2023）针对骨肉瘤基因表达数据分类问题，提出了一种基于加权多源数据融合、激励卷积神经网络和支持向量机的分类模型，针对胃癌 DNA 甲基化数据分类问题，提出了一种增强随机森林和激励堆叠自编码器的分类模型，并验证了这两个模型均能准确分类并避免“过拟合”现象。

总结类别判断中机器学习算法的发展态势，发现其呈现多种分类器的集成和优化、深度学习的广泛使用、多源数据融合的特性。

新类识别：

新类识别是机器学习中聚类的应用。它指挖掘基因表达数据的潜在信息，以发现新的基因调控网络和样本类型。传统的机器学习方法中可用于新类识别的有层次聚类分析法、SOM 方法、贝叶斯概率框架等。

在肿瘤新亚型的探索研究中，刘健^[6]（2019）提出了基于离散约束及封顶范数的鲁棒低秩子空间聚类算法，并同时考虑肿瘤数据中的样本流形结构和基因流形结构，他提出了基于双超图正则化主成分分析的双聚类算法并证实了它们的有效性；Jothi, R., Mohanty, S. K., and Ojha, A. 等人^[14]（2019）通过约束双分区方法探索一组可能的中心，提出了一种确定性 K-means 初始化算法（DK-means），将所提出的算法与具有随机初始化的经典 K-means 以及改进的 K-means 变体进行了比较，验证了 DK-means 具有更快、更稳定的收敛以及更好的聚类质量。廖旭红^[15]（2023）针对基因表达数据在线学习场景，构建样本-基因索引结，提出最近邻样本查询算法，并对搜集的全局离群点定义了一种内聚-分离度指标用于新类识别算法；张陆星^[9]（2021）提出了一种新的基于 LRR 的方法——基于 Huber 损失和序数局部性的块对角低秩表示（HOB LRR），并验证了其在癌症样本聚类上的优良性能。

总结新类识别中机器学习算法的发展态势，发现其主要聚焦在对传统聚类算法的改进。由于双聚类在基因表达数据的研究中充分挖掘了数据信息，所以要求用于新类识别的机器学习算法拥有整合多维度数据的能力。

预后预测：

预后预测是指根据个体的基因表达数据，来预测患者的疾病进展和复发风险、生存概率等。这类研究通过分析患者样本中的基因表达模式，尝试找到与疾病发展和生存率相关的特征和模式，从而帮助医生和研究人员做出更准确的预后评估和治疗决策。

宋博文^[16]（2023）基于两种癌症转录组数据提出了两种预后预测模型，第一种模型是基于深度卷积生成对抗网络和卷积神经网络的预后预测模型，并验证其在两组不同数据集上有明显预测优势。第二种模型是基于长短期记忆网络与卷积神经网络的预后预测模型； Ziga Avsec¹, Vikram Agarwal^{2,4}, Daniel Visentin 等^[17]（2021）基于自注意力机制，构建了一种新型神经网络架构——Enformer，用于预测人类和小鼠基因组中 DNA 序列的基因表达和染色质状态，他们的研究显著提高了基因表达预测的准确性；王泽朋，李坤鹏，周玉等人^[18]（2024）在混合式特征选择获取关键基因集基础上，构建并比较了基于多层感知器（MLP）、逻辑回归、决策树等 8 种机器学习算法的诊断预测模型，得出 MLP 是最佳胃癌预测模型。

观察用于预后预测的机器学习方法，可以发现研究人员正在尝试结合不同类型的机器学习模型，如深度学习、生成对抗网络等，以构建更加复杂和高效的预测模型，进一步提高预测的准确性和稳定性。

四、 基于机器学习的基因表达数据分析的未来趋势（15 分）

基于机器学习的基因表达数据分析未来趋势可以从数据来源和数据应用两个方面分析。

针对数据来源方面，我认为基因表达数据有如下趋势：

RNA-seq 数据将逐渐取代 c-DNA 数据，成为用于研究的主流基因表达数据：传统基因微阵列数据对实验环境的变化十分敏感，且收集成本高昂、数据噪声多；而 RNA 测序数据能够提供更全面、精准的基因表达谱，对极高或极低的基因表达水平都有高精度的量化，还具有低噪声、低成本、数据应用范围广等优势。此外，Alharbi F^[19]等人的研究中还提到了单细胞 RNA 测序技术能在单个细胞水平上总结基因表达，揭示细胞的异质性，对更精细地定位与挖掘基因表达信息、研究疾病底层作用机理有很大的帮助。而基于 RNA-seq 的机器学习算法也正不断完善。

多组学、多模态大数据分析趋势：基因表达数据作为基因组学的一部分，未来将与转录组学、蛋白质组学、代谢组学等众多组学方法结合，形成复杂多源的多组学数据，共同被用以复杂疾病的研究。由于疾病的产生通常是多通路、多器官参与的，单组学数据难以完全、准确地阐述致病机制与调控过程，所以需要整合更多类型的组学数据以获取更全面的生物学信息。研究^[20]表明基于机器学习对高血压多组学数据整合，有效提高了模型预测效果，并为揭示复杂疾病的分子间相互作用规律提供研究思路。

除了基因表达层次上不同组学的数据融合，数据类型上不同组学的数据联合研究也将成为未来发展趋势。王慧娜等人^[21]将乳腺癌的基因表达数据和乳腺癌影像数据结合，并用机器学习方法进行乳腺癌分类预测、用深度学习方法进行乳腺癌影像分割。机器学习方法在不同类型数据上具有广泛的适用性，可以预见，这种基于不同模态的数据融合在未来也具有很大的可挖掘性。

针对数据应用方面，我认为基于机器学习的基因表达数据分析有如下趋势：

深度学习算法的广泛使用：基因表达数据由于其高维度、小样本特性，在传统机器学习训练时难以被充分利用。深度学习模型因其强大的特征提取能力、对复杂数据模式的识别能力，在处理高维、非线性的基因表达数据时呈现出明显的优势，上文提及的维度高达上万的 RNA-seq 数据的广泛使用对机器学习算法作出了更高要求。容易发现深度学习在第三部分综述中涉及的两个类别的任务上都有超于传统机器学习的优良表现。近年来对用于基因表达数据的机器学习算法的研究也主要集中在改进深度学习算法以挖掘更层次的信息上。

对模型可解释性的追求：对基因表达数据分析的最终目的是希望从数据中挖掘信息，用于生物学和医学疾病机理的探究等，所以所构建机器学习模型的可解释性对理解生物学机制、促进临床应用等具有重要的意义。

传统的机器学习方法结构简单，易于理解，可解释性高，但对于高维数据处理能力欠缺，所以未来发展趋势将集中在对传统机器学习模型适应性和鲁棒性的提升上；深度学习模型对高维数据训练能力好，但模型类似“黑箱”，通常难以直观理解，所以未来发展趋势将集中在增强深度模型的可解释性上。齐涵等人指出，基于临床医学、统计学、生物信息学、计算机科学等多学科交叉合作的研究有助于从原理和算法的多重角度联合理解生物学机制。

实时在线学习趋势：一些疾病的监测与响应治疗对时效性具有很高的要求，这要求模型在接收到新数据时不断更新与改进，是一种增量学习方法。目前已有在线 PCA、在线随机森林、流式 Boosting 等用于实时在线学习的机器学习算法，但在算法稳定性和数据可靠性等方面仍存在许多挑战。未来对稳定的、适应性强的实时在线学习算法的开发可能是发展趋势之一。

参考文献

- [1]Bhandari N, Walambe R, Kotecha K, Khare SP. A comprehensive survey on computational learning methods for analysis of gene expression data. *Front Mol Biosci*. 2022 Nov 7;9:907150. doi: 10.3389/fmolb.2022.907150. PMID: 36458095; PMCID: PMC9706412.
- [2]Vadapalli S, Abdelhalim H, Zeeshan S, Ahmed Z. Artificial intelligence and machine learning approaches using gene expression and variant data for personalized medicine. *Brief Bioinform*. 2022 Sep 20;23(5):bbac191. doi: 10.1093/bib/bbac191. PMID: 35595537; PMCID: PMC10233311.
- [3]韩旭. 基于机器学习算法的基因表达数据处理与分析[D].天津大学,2020.DOI:10.27356/d.cnki.gtjdu.2018.000638.
- [4]Qiu Y L, Zheng H, Gevaert O. A deep learning framework for imputing missing values in genomic data[J]. *BioRxiv*, 2020: 406066.
- [5]肖雅雯. 基于基因表达数据深度学习的癌症诊断研究[D].上海交通大学,2022.DOI:10.27307/d.cnki.gsjtu.2020.000051.
- [6]刘健. 基于机器学习的肿瘤基因表达谱数据分析方法研究[D].中国矿业大学,2019.
- [7]李胜斌. 基于基因表达谱数据的特征选择方法研究[D].河南大学,2023.DOI:10.27114/d.cnki.ghnau.2022.000004.
- [8]张晶. 基于基因表达数据的肝癌特征基因选取及生存分析[D].南京审计大学,2022.DOI:10.27835/d.cnki.gnjsj.2022.000337.
- [9]张陆星. 面向基因表达数据的特征基因选择与癌症分类聚类算法研究[D].南京理工大学,2024.DOI:10.27241/d.cnki.gnjgu.2021.003078.
- [10]张佳航. 基于基因表达数据和机器学习技术探索非小细胞肺癌及其亚型[D].天津大学,2023.DOI:10.27356/d.cnki.gtjdu.2021.000040.
- [11]李少川. 深度学习在癌症亚型诊断中的应用研究[D].东北师范大学, 2023.DOI:10.27011/d.cnki.gdbsu.2022.001461.
- [12]杨磊. 面向基因表达数据的代价敏感学习优化方法[D].中国计量大学,2020.
- [13]张强. 面向癌症患者基因表达数据的分类模型研究[D].江南大学,2024.DOI:10.27169/d.cnki.gwqgu.2023.000406.
- [14]Jothi, R., Mohanty, S. K., and Ojha, A. (2019). DK-Means: A deterministic K-means clustering algorithm for gene expression analysis. *Pattern Anal. Appl.* 22(2), 649–667.
- [15]廖旭红. 基因表达数据关键基因与新类识别算法研究[D].湖南理工学院,2023.DOI:10.27906/d.cnki.gnghy.2023.000199.

- [16]宋博文. 基于深度学习的癌症生存预后预测模型研究[D]. 吉林大学,2024.DOI: 10.27162/d.cnki.gjlin.2023.006248.
- [17]Avsec Ž, Agarwal V, Visentin D, Ledsam JR, Grabska-Barwinska A, Taylor KR, Assael Y, Jumper J, Kohli P, Kelley DR. Effective gene expression prediction from sequence by integrating long-range interactions. *Nat Methods*. 2021 Oct;18(10):1196-1203. doi: 10.1038/s41592-021-01252-x. Epub 2021 Oct 4. PMID: 34608324; PMCID: PMC8490152.
- [18]王泽朋,李坤鹏,周玉,等.基于机器学习的胃癌关键基因筛选及预测模型构建[J].中国医学物理学杂志,2024,41(01):115-124.
- [19]Alharbi F, Vakanski A. Machine Learning Methods for Cancer Classification Using Gene Expression Data: A Review. *Bioengineering (Basel)*. 2023 Jan 28;10(2):173. doi: 10.3390/bioengineering10020173. PMID: 36829667; PMCID: PMC9952758
- [20]齐涵,杨晓俊,温馥源,等.多组学大数据分析方法在高血压研究中的应用进展[J].中华高血压杂志(中英文),2024,32(02):119-126.DOI:10.16439/j.issn.1673-7245.2024.02.005.
- [21]王慧娜,李金书,李建强,等.基于机器学习的乳腺癌影像基因组学研究综述[J/O L].北京工业大学学报,2024(06):1-15[2024-06-15].<http://kns.cnki.net/kcms/detail/11.2286.T.20240510.1645.004.html>.